

A Closer Look at the Limitations of Instruction Tuning

	Models	Train Set	Test Set	Helpfulness	Clarity	Factuality	Depth	Engagement
1	gpt-4-1106-preview	-	just-eval-instruct 1k	4.94	5.0	4.9	4.71	4.31
2	gpt-4-1106-preview	-	MedInstruct-test 216	4.99	5.0	4.98	4.86	4.25
3	LLaMa-2 7B-chat-hf	-	just-eval-instruct 1k	4.21	4.94	4.34	4.33	4.77
4	LLaMa-2 7B-chat-hf	-	MedInstruct-test 216	4.96	4.96	4.86	4.65	4.82
5	LLaMa-2 13B-chat-hf	-	just-eval-instruct 1k	4.36	4.93	4.48	4.39	4.72
6	LLaMa-2 13B-chat-hf	-	MedInstruct-test 216	4.67	4.88	4.89	4.72	4.83
7	LLaMa-2 70B-chat-hf	-	just-eval-instruct 1k	4.54	4.93	4.67	4.45	4.82
8	LLaMa-2 70B-chat-hf	-	MedInstruct-test 216	4.82	4.91	4.92	4.81	4.87
9	LLaMa-2 7B-LFT	databricks-dolly 15k	just-eval-instruct 1k	2.67	3.29	3.02	1.77	2.09
10	LLaMa-2 7B-SFT	databricks-dolly 15k	just-eval-instruct 1k	2.3	3.04	2.38	1.64	2.08
11	LLaMa-2 7B-LFT	databricks-dolly 15k	MedInstruct-test 216	3.40	4.10	3.94	2.26	2.56
12	LLaMa-2 7B-SFT	databricks-dolly 15k	MedInstruct-test 216	2.65	3.22	2.63	1.85	2.34
13	LLaMa-2 7B-LFT	LIMA 1K	just-eval-instruct 1k	2.89	3.25	2.94	2.17	2.27
14	LLaMa-2 7B-SFT	LIMA 1K	just-eval-instruct 1k	2.47	2.91	2.32	1.93	2.23
15	LLaMa-2 7B-LFT	LIMA 1K	MedInstruct-test 216	3.84	4.27	3.95	2.90	2.91
16	LLaMa-2 7B-SFT	LIMA 1K	MedInstruct-test 216	3.35	3.75	3.11	2.51	2.75
17	LLaMa-2 7B-LFT	MedInstruct 1K	MedInstruct-test 216	4.54	4.82	4.63	3.69	3.33
18	LLaMa-2 7B-SFT	MedInstruct 1K	MedInstruct-test 216	3.70	4.19	3.44	2.95	3.07
19	LLaMa-2 7B-LFT	MedInstruct 10K	MedInstruct-test 216	4.55	4.81	4.56	3.50	3.32
20	LLaMa-2 7B-SFT	MedInstruct 10K	MedInstruct-test 216	4.16	4.51	4.11	3.25	3.20
21	LLaMa-2 7B-LFT	MedInstruct 25K	MedInstruct-test 216	4.60	4.84	4.68	3.60	3.38
22	LLaMa-2 7B-SFT	MedInstruct 25K	MedInstruct-test 216	4.40	4.69	4.30	3.48	3.35
23	LLaMa-2 7B-LFT	MedInstruct 52K	MedInstruct-test 216	4.53	4.78	4.55	3.62	3.39
24	LLaMa-2 7B-SFT	MedInstruct 52K	MedInstruct-test 216	4.38	4.68	4.37	3.47	3.36
25	LLaMa-2 7B-LFT	Alpaca 1K	just-eval-instruct 1k	3.17	3.95	3.30	2.08	2.52
26	LLaMa-2 7B-SFT	Alpaca 1K	just-eval-instruct 1k	2.25	3.11	2.46	1.58	2.08
27	LLaMa-2 7B-LFT	Alpaca 10K	just-eval-instruct 1k	3.25	4.05	3.36	2.06	2.52
28	LLaMa-2 7B-SFT	Alpaca 10K	just-eval-instruct 1k	2.31	3.09	2.34	1.65	2.13
29	LLaMa-2 7B-LFT	Alpaca 25K	just-eval-instruct 1k	3.29	4.05	3.41	2.12	2.53
30	LLaMa-2 7B-SFT	Alpaca 25K	just-eval-instruct 1k	2.44	3.24	2.46	1.71	2.17
31	LLaMa-2 7B-LFT	Alpaca 52K	just-eval-instruct 1k	3.36	4.14	3.42	2.18	2.61
32	LLaMa-2 7B-SFT	Alpaca 52K	just-eval-instruct 1k	2.57	3.31	2.07	1.82	2.33
33	LLaMa-2 7B-LFT	Tulu-V2-Mix 1K	MedInstruct-test 216	4.21	4.64	4.35	3.19	3.11
34	LLaMa-2 7B-LFT	Tulu-V2-Mix 1K	just-eval-instruct 1k	3.46	3.99	3.48	2.52	2.71
35	LLaMa-2 7B-SFT	Tulu-V2-Mix 1K	just-eval-instruct 1k	2.17	2.75	2.13	1.71	2.05
36	LLaMa-2 7B-LFT	Tulu-V2-Mix 10K	just-eval-instruct 1k	3.58	4.06	3.54	2.63	2.84
37	LLaMa-2 7B-SFT	Tulu-V2-Mix 10K	just-eval-instruct 1k	2.55	3.16	2.48	1.99	2.39
38	LLaMa-2 7B-LFT	Tulu-V2-Mix 25K	just-eval-instruct 1k	3.64	4.18	3.62	2.69	2.92
39	LLaMa-2 7B-SFT	Tulu-V2-Mix 25K	just-eval-instruct 1k	2.56	3.16	2.47	1.97	2.38
40	LLaMa-2 7B-LFT	Tulu-V2-Mix 50K	just-eval-instruct 1k	3.78	4.3	3.67	2.73	2.98
41	LLaMa-2 7B-SFT	Tulu-V2-Mix 50K	just-eval-instruct 1k	2.57	3.16	2.45	1.98	2.37
42	LLaMa-2 7B-LFT	Tulu-V2-Mix 150K	just-eval-instruct 1k	3.77	4.27	3.66	2.99	2.97
43	LLaMa-2 7B-SFT	Tulu-V2-Mix 150K	just-eval-instruct 1k	2.72	3.31	2.59	2.77	2.44
44	LLaMa-2 7B-LFT	Tulu-V2-Mix 326k	just-eval-instruct 1k	3.85	4.34	3.72	2.8	3.03
45	LLaMa-2 7B-SFT	Tulu-V2-Mix 326k	just-eval-instruct 1k	3.24	4.02	3.35	2.43	2.72
46	LLaMa-2 7B-LFT	filtered-dolly 3k	just-eval-instruct 1k	2.76	3.44	3.02	1.83	2.15
47	LLaMa-2 7B-SFT	filtered-dolly 3k	just-eval-instruct 1k	1.8	2.37	1.91	1.33	1.68
48	LLaMa-2 7B-LFT	Evol-Instruct 70k	just-eval-instruct 1k	3.79	4.32	3.68	2.75	2.93
49	LLaMa-2 7B-SFT	Evol-Instruct 70k	just-eval-instruct 1k	2.87	3.52	2.65	2.13	2.59
50	LLaMa-2 7B-LFT	LIMA-Simple 1k	just-eval-instruct 1k	3.70	3.66	3.16	2.08	2.44
51	LLaMa-2 7B-LFT	chatgpt 9k	just-eval-instruct 1k	3.33	4.05	3.34	2.15	2.59
52	LLaMa-2 7B-SFT	chatgpt 9k	just-eval-instruct 1k	3.02	3.86	3.1	2.13	2.56
53	LLaMa-2 7B-NFT	Alpaca 52K	just-eval-instruct 1k	2.45	3.12	2.47	1.76	2.18
54	LLaMa-2 7B-NFT	MedInstruct 52K	just-eval-instruct 1k	4.18	4.53	4.25	3.29	3.28

Table 13. Results Table 1

A Closer Look at the Limitations of Instruction Tuning

	Models	Train Set	Test Set	Helpfulness	Clarity	Factuality	Depth	Engagement
1	LLaMa-2 _{13B} -LFT	databricks-dolly _{15k}	just-eval-instruct _{1k}	2.88	3.54	3.21	1.83	2.19
2	LLaMa-2 _{13B} -SFT	databricks-dolly _{15k}	just-eval-instruct _{1k}	2.44	3.15	2.51	1.71	2.18
3	LLaMa-2 _{13B} -LFT	databricks-dolly _{15k}	MedInstruct-test ₂₁₆	3.58	4.26	4.19	2.39	2.69
4	LLaMa-2 _{13B} -SFT	databricks-dolly _{15k}	MedInstruct-test ₂₁₆	2.91	3.56	2.87	2.02	2.55
5	LLaMa-2 _{13B} -LFT	LIMA _{1K}	just-eval-instruct _{1k}	3.08	3.40	3.12	2.27	2.42
6	LLaMa-2 _{13B} -SFT	LIMA _{1K}	just-eval-instruct _{1k}	2.26	2.81	2.23	1.77	2.11
7	LLaMa-2 _{13B} -LFT	LIMA _{1K}	MedInstruct-test ₂₁₆	4.16	4.50	4.31	3.17	3.04
8	LLaMa-2 _{13B} -SFT	LIMA _{1K}	MedInstruct-test ₂₁₆	2.80	3.26	2.66	2.18	2.48
9	LLaMa-2 _{13B} -LFT	MedInstruct _{1K}	MedInstruct-test ₂₁₆	4.54	4.82	4.63	3.69	3.33
10	LLaMa-2 _{13B} -SFT	MedInstruct _{1K}	MedInstruct-test ₂₁₆	4.7	4.90	4.75	3.91	3.45
11	LLaMa-2 _{13B} -LFT	MedInstruct _{10K}	MedInstruct-test ₂₁₆	4.7	4.93	4.84	3.68	3.40
12	LLaMa-2 _{13B} -SFT	MedInstruct _{10K}	MedInstruct-test ₂₁₆	4.31	4.69	4.29	3.36	3.25
13	LLaMa-2 _{13B} -LFT	MedInstruct _{25K}	MedInstruct-test ₂₁₆	4.74	4.92	4.78	3.74	3.43
14	LLaMa-2 _{13B} -SFT	MedInstruct _{25K}	MedInstruct-test ₂₁₆	4.11	4.49	4.04	3.25	3.18
15	LLaMa-2 _{13B} -LFT	MedInstruct _{52K}	MedInstruct-test ₂₁₆	4.63	4.83	4.74	3.62	3.36
16	LLaMa-2 _{13B} -SFT	MedInstruct _{52K}	MedInstruct-test ₂₁₆	4.27	4.55	4.21	3.31	3.24
17	LLaMa-2 _{13B} -LFT	Alpaca _{1K}	just-eval-instruct _{1k}	3.39	4.17	3.55	2.19	2.61
18	LLaMa-2 _{13B} -SFT	Alpaca _{1K}	just-eval-instruct _{1k}	2.37	3.22	2.51	1.68	2.13
19	LLaMa-2 _{13B} -LFT	Alpaca _{10K}	just-eval-instruct _{1k}	3.51	4.27	3.57	2.24	2.64
20	LLaMa-2 _{13B} -SFT	Alpaca _{10K}	just-eval-instruct _{1k}	2.38	3.20	2.45	1.67	2.20
21	LLaMa-2 _{13B} -LFT	Alpaca _{25K}	just-eval-instruct _{1k}	3.48	4.22	3.59	2.21	2.67
22	LLaMa-2 _{13B} -SFT	Alpaca _{25K}	just-eval-instruct _{1k}	2.20	2.98	2.28	1.56	2.01
23	LLaMa-2 _{13B} -LFT	Alpaca _{52K}	just-eval-instruct _{1k}	3.54	4.24	3.61	2.30	2.67
24	LLaMa-2 _{13B} -SFT	Alpaca _{52K}	just-eval-instruct _{1k}	2.31	3.01	2.31	1.71	2.21
25	LLaMa-2 _{13B} -LFT	Tulu-V2-Mix _{1K}	just-eval-instruct _{1k}	3.72	4.22	3.76	2.71	2.88
26	LLaMa-2 _{13B} -SFT	Tulu-V2-Mix _{1K}	just-eval-instruct _{1k}	2.63	3.33	2.57	1.99	2.42
27	LLaMa-2 _{13B} -LFT	Tulu-V2-Mix _{10K}	just-eval-instruct _{1k}	3.84	4.28	3.77	2.86	2.99
28	LLaMa-2 _{13B} -SFT	Tulu-V2-Mix _{10K}	just-eval-instruct _{1k}	2.72	3.35	2.63	2.09	2.51
29	LLaMa-2 _{13B} -LFT	Tulu-V2-Mix _{25K}	just-eval-instruct _{1k}	3.95	4.38	3.89	2.88	3.02
30	LLaMa-2 _{13B} -SFT	Tulu-V2-Mix _{25K}	just-eval-instruct _{1k}	2.69	3.26	2.65	2.05	2.37
31	LLaMa-2 _{13B} -LFT	Tulu-V2-Mix _{50K}	just-eval-instruct _{1k}	4.01	4.5	3.96	2.87	3.08
32	LLaMa-2 _{13B} -SFT	Tulu-V2-Mix _{50K}	just-eval-instruct _{1k}	2.66	3.09	2.67	1.97	2.24
33	LLaMa-2 _{13B} -LFT	Tulu-V2-Mix _{150K}	just-eval-instruct _{1k}	4.08	4.51	3.93	3.02	3.16
34	LLaMa-2 _{13B} -SFT	Tulu-V2-Mix _{150K}	just-eval-instruct _{1k}	2.93	3.52	2.77	2.22	2.6
35	LLaMa-2 _{13B} -LFT	Tulu-V2-Mix _{326k}	just-eval-instruct _{1k}	4.1	4.57	4.05	2.94	3.17
36	LLaMa-2 _{13B} -SFT	Tulu-V2-Mix _{326k}	just-eval-instruct _{1k}	3.23	3.87	3.33	2.69	2.98
37	LLaMa-2 _{70B} -LFT	databricks-dolly _{15k}	just-eval-instruct _{1k}	3.36	3.92	3.75	2.35	2.57
38	LLaMa-2 _{70B} -SFT	databricks-dolly _{15k}	just-eval-instruct _{1k}	2.82	3.56	2.99	2.12	2.58
39	LLaMa-2 _{70B} -LFT	LIMA _{1K}	just-eval-instruct _{1k}	3.28	3.72	3.51	2.41	2.82
40	LLaMa-2 _{70B} -SFT	LIMA _{1K}	just-eval-instruct _{1k}	2.56	3.11	2.53	2.25	2.31
41	LLaMa-2 _{70B} -LFT	MedInstruct _{1K}	MedInstruct-test ₂₁₆	4.81	4.92	4.88	3.45	3.98
42	LLaMa-2 _{70B} -SFT	MedInstruct _{1K}	MedInstruct-test ₂₁₆	4.34	4.51	3.93	3.51	3.56
43	LLaMa-2 _{70B} -LFT	MedInstruct _{52K}	MedInstruct-test ₂₁₆	4.63	4.83	4.74	3.62	3.36
44	LLaMa-2 _{70B} -SFT	MedInstruct _{52K}	MedInstruct-test ₂₁₆	4.27	4.55	4.21	3.31	3.24
45	LLaMa-2 _{70B} -LFT	Tulu-V2-Mix _{1K}	MedInstruct-test ₂₁₆	4.43	4.72	4.56	3.86	3.76
46	LLaMa-2 _{70B} -LFT	Alpaca _{1K}	just-eval-instruct _{1k}	3.54	4.28	3.88	3.91	3.24
47	LLaMa-2 _{70B} -SFT	Alpaca _{1K}	just-eval-instruct _{1k}	2.94	3.45	2.78	2.45	3.24
48	LLaMa-2 _{70B} -LFT	Alpaca _{52K}	just-eval-instruct _{1k}	4.04	4.65	4.11	3.21	2.98
49	LLaMa-2 _{70B} -SFT	Alpaca _{52K}	just-eval-instruct _{1k}	2.71	3.45	2.66	2.45	3.54
50	LLaMa-2 _{70B} -LFT	Tulu-V2-Mix _{1k}	just-eval-instruct _{1k}	4.21	4.56	4.25	3.53	2.51
51	LLaMa-2 _{70B} -SFT	Tulu-V2-Mix _{1k}	just-eval-instruct _{1k}	3.09	3.78	3.12	2.54	2.98
52	LLaMa-2 _{70B} -LFT	Tulu-V2-Mix _{326k}	just-eval-instruct _{1k}	4.36	4.76	4.43	3.54	3.66
53	LLaMa-2 _{70B} -SFT	Tulu-V2-Mix _{326k}	just-eval-instruct _{1k}	3.76	4.01	3.75	2.98	3.24

Table 14. Results table 2

A Closer Look at the Limitations of Instruction Tuning

	Models	Train Set	Test Set	Helpfulness	Clarity	Factuality	Depth	Engagement
1	Mistral-v0.1 7B_LFT	databricks-dolly 15k	just-eval-instruct 1k	3.13	3.83	3.45	1.99	2.34
2	Mistral-v0.1 7B_SFT	databricks-dolly 15k	just-eval-instruct 1k	1.12	1.32	1.27	1.04	1.11
3	Mistral-v0.1 7B_LFT	databricks-dolly 15k	MedInstruct-test 216	3.73	4.47	4.29	2.52	2.77
4	Mistral-v0.1 7B_SFT	databricks-dolly 15k	MedInstruct-test 216	1.09	1.11	1.11	1.03	1.08
5	Mistral-v0.1 7B_LFT	LIMA 1K	just-eval-instruct 1k	3.21	3.65	3.3	2.39	2.48
6	Mistral-v0.1 7B_SFT	LIMA 1K	just-eval-instruct 1k	1.49	1.83	1.58	1.23	1.5
7	Mistral-v0.1 7B_LFT	LIMA 1K	MedInstruct-test 216	4.24	4.49	4.48	3.18	3.08
8	Mistral-v0.1 7B_SFT	LIMA 1K	MedInstruct-test 216	1.71	1.83	1.66	1.31	1.6
9	Mistral-v0.1 7B_LFT	MedInstruct 1K	MedInstruct-test 216	4.85	4.97	4.89	4.77	4.54
10	Mistral-v0.1 7B_SFT	MedInstruct 1K	MedInstruct-test 216	1.09	1.56	1.27	1.10	1.22
11	Mistral-v0.1 7B_LFT	MedInstruct 10K	MedInstruct-test 216	4.92	4.98	4.93	4.84	4.6
12	Mistral-v0.1 7B_SFT	MedInstruct 10K	MedInstruct-test 216	1.18	1.78	1.38	1.16	1.32
13	Mistral-v0.1 7B_LFT	MedInstruct 25K	MedInstruct-test 216	4.88	4.98	4.94	4.78	4.58
14	Mistral-v0.1 7B_SFT	MedInstruct 25K	MedInstruct-test 216	1.06	1.08	1.12	1.04	1.06
15	Mistral-v0.1 7B_LFT	MedInstruct 52K	MedInstruct-test 216	4.9	4.98	4.94	4.83	4.56
16	Mistral-v0.1 7B_SFT	MedInstruct 52K	MedInstruct-test 216	1.26	2.1	1.87	1.34	1.88
17	Mistral-v0.1 7B_LFT	Alpaca 1K	just-eval-instruct 1k	4.24	4.79	4.19	3.51	3.62
18	Mistral-v0.1 7B_SFT	Alpaca 1K	just-eval-instruct 1k	1.13	2.6	1.49	1.1	1.42
19	Mistral-v0.1 7B_LFT	Alpaca 10K	just-eval-instruct 1k	4.28	4.87	4.23	3.38	3.55
20	Mistral-v0.1 7B_SFT	Alpaca 10K	just-eval-instruct 1k	1.11	2.34	1.33	1.1	1.22
21	Mistral-v0.1 7B_LFT	Alpaca 25K	just-eval-instruct 1k	4.3	4.86	4.25	3.5	3.67
22	Mistral-v0.1 7B_SFT	Alpaca 25K	just-eval-instruct 1k	1.01	1.75	1.13	1	1.03
23	Mistral-v0.1 7B_LFT	Alpaca 52K	just-eval-instruct 1k	4.3	4.88	4.29	3.43	3.58
24	Mistral-v0.1 7B_SFT	Alpaca 52K	just-eval-instruct 1k	1.04	1.77	1.2	1.03	1.09
25	Phi-1.5 1.3B_LFT	databricks-dolly 15k	just-eval-instruct 1k	3.00	3.78	3.25	1.92	2.33
26	Phi-1.5 1.3B_SFT	databricks-dolly 15k	just-eval-instruct 1k	2.37	3.15	2.51	1.69	2.14
27	Phi-1.5 1.3B_LFT	databricks-dolly 15k	MedInstruct-test 216	3.83	4.59	4.38	2.53	2.79
28	Phi-1.5 1.3B_SFT	databricks-dolly 15k	MedInstruct-test 216	3.09	3.87	3.45	2.08	2.58
29	Phi-1.5 1.3B_LFT	LIMA 1K	just-eval-instruct 1k	3.98	4.46	3.93	3.85	3.82
30	Phi-1.5 1.3B_SFT	LIMA 1K	just-eval-instruct 1k	3.71	3.49	3.18	3.39	3.25
31	Phi-1.5 1.3B_LFT	LIMA 1K	MedInstruct-test 216	4.56	4.85	4.54	3.55	3.26
32	Phi-1.5 1.3B_SFT	LIMA 1K	MedInstruct-test 216	4.35	4.7	3.97	3.36	3.34
33	Phi-1.5 1.3B_LFT	MedInstruct 1K	MedInstruct-test 216	4.32	4.26	4.33	4.29	4.16
34	Phi-1.5 1.3B_SFT	MedInstruct 1K	MedInstruct-test 216	3.52	3.74	3.44	3.31	3.23
35	Phi-1.5 1.3B_LFT	MedInstruct 10K	MedInstruct-test 216	4.34	4.27	4.39	4.31	4.19
36	Phi-1.5 1.3B_SFT	MedInstruct 10K	MedInstruct-test 216	3.72	3.84	3.55	3.44	3.42
37	Phi-1.5 1.3B_LFT	MedInstruct 25K	MedInstruct-test 216	4.39	4.28	4.44	4.33	4.21
38	Phi-1.5 1.3B_SFT	MedInstruct 25K	MedInstruct-test 216	3.87	3.92	3.74	3.52	3.43
39	Phi-1.5 1.3B_LFT	MedInstruct 52K	MedInstruct-test 216	4.41	4.32	4.51	4.69	4.53
40	Phi-1.5 1.3B_SFT	MedInstruct 52K	MedInstruct-test 216	4.15	4.11	4.10	4.24	4.30
41	Phi-1.5 1.3B_LFT	Alpaca 1K	just-eval-instruct 1k	4.07	4.85	4.06	3.4	3.64
42	Phi-1.5 1.3B_SFT	Alpaca 1K	just-eval-instruct 1k	3.19	4.42	3.31	2.72	3.25
43	Phi-1.5 1.3B_LFT	Alpaca 10K	just-eval-instruct 1k	4.05	4.84	4.02	3.26	3.54
44	Phi-1.5 1.3B_SFT	Alpaca 10K	just-eval-instruct 1k	3.13	4.13	3.23	2.67	3.24
45	Phi-1.5 1.3B_LFT	Alpaca 25K	just-eval-instruct 1k	4.03	4.79	4.02	3.29	3.54
46	Phi-1.5 1.3B_SFT	Alpaca 25K	just-eval-instruct 1k	3.04	4.49	3.11	2.64	3.28
47	Phi-1.5 1.3B_LFT	Alpaca 52K	just-eval-instruct 1k	4.07	4.81	4.03	3.33	3.56
48	Phi-1.5 1.3B_SFT	Alpaca 52K	just-eval-instruct 1k	3.93	4.2	3.65	3.88	3.49

Table 15. Results table 3

A Closer Look at the Limitations of Instruction Tuning

	Models	Train Set	Test Set	Coding	Info-Seek	Math	Procedure	Reasoning	Role-Play	Writing
1	gpt-4-1106-preview	-	just-eval-instruct 1k	4.67	4.78	4.57	4.87	4.80	4.76	4.76
2	LLaMa-2 7B-chat-hf	-	just-eval-instruct 1k	3.31	3.73	2.54	4.07	3.93	3.94	4.07
3	LLaMa-2 13B-chat-hf	-	just-eval-instruct 1k	3.27	4.02	2.84	4.22	4.09	4.11	4.32
4	LLaMa-2 70B-chat-hf	-	just-eval-instruct 1k	4.02	4.41	3.67	4.76	4.56	4.45	4.81
5	LLaMa-2 7B-LFT	databricks-dolly 15k	just-eval-instruct 1k	2.38	2.73	1.81	2.53	2.55	2.15	2.36
6	LLaMa-2 7B-SFT	databricks-dolly 15k	just-eval-instruct 1k	1.78	2.32	1.62	2.21	2.43	2.46	2.43
7	LLaMa-2 7B-LFT	LIMA 1k	just-eval-instruct 1k	2.37	2.78	1.72	2.87	2.68	2.65	2.63
8	LLaMa-2 7B-SFT	LIMA 1k	just-eval-instruct 1k	1.76	2.48	1.25	2.45	2.58	2.05	2.3
9	LLaMa-2 7B-LFT	Alpaca 1k	just-eval-instruct 1k	2.47	3.11	1.95	3.0	3.1	2.72	2.97
10	LLaMa-2 7B-SFT	Alpaca 1k	just-eval-instruct 1k	1.79	2.34	1.51	2.4	2.45	2.06	2.27
11	LLaMa-2 7B-LFT	Alpaca 10k	just-eval-instruct 1k	2.45	3.17	1.99	2.99	3.13	2.86	3.1
12	LLaMa-2 7B-SFT	Alpaca 10k	just-eval-instruct 1k	1.75	2.26	1.53	2.23	2.5	2.29	2.69
13	LLaMa-2 7B-LFT	Alpaca 25k	just-eval-instruct 1k	2.57	3.17	2.09	3.02	3.13	2.96	3.13
14	LLaMa-2 7B-SFT	Alpaca 25k	just-eval-instruct 1k	1.88	2.36	1.51	2.41	2.58	2.52	2.74
15	LLaMa-2 7B-LFT	Alpaca 52k	just-eval-instruct 1k	2.74	3.21	2.09	3.17	3.15	2.97	3.3
16	LLaMa-2 7B-SFT	Alpaca 52k	just-eval-instruct 1k	1.54	2.15	1.41	2.28	2.39	2.3	2.48
17	LLaMa-2 7B-LFT	Tulu-V2-Mix 1k	just-eval-instruct 1k	2.66	3.39	2.01	3.29	3.44	2.92	3.12
18	LLaMa-2 7B-SFT	Tulu-V2-Mix 1k	just-eval-instruct 1k	1.61	2.2	1.37	2.33	2.37	2.11	2.18
19	LLaMa-2 7B-LFT	Tulu-V2-Mix 10k	just-eval-instruct 1k	2.58	3.46	2.14	3.38	3.54	3.23	3.34
20	LLaMa-2 7B-SFT	Tulu-V2-Mix 10k	just-eval-instruct 1k	1.85	2.45	1.3	2.57	2.84	2.54	2.79
21	LLaMa-2 7B-LFT	Tulu-V2-Mix 25k	just-eval-instruct 1k	2.69	3.53	2.15	3.41	3.60	3.37	3.52
22	LLaMa-2 7B-SFT	Tulu-V2-Mix 25k	just-eval-instruct 1k	1.95	2.43	1.31	2.56	2.84	2.58	2.86
23	LLaMa-2 7B-LFT	Tulu-V2-Mix 50k	just-eval-instruct 1k	2.82	3.6	2.16	3.45	3.67	3.48	3.6
24	LLaMa-2 7B-SFT	Tulu-V2-Mix 50k	just-eval-instruct 1k	2.1	2.41	1.30	2.38	2.83	2.67	2.91
25	LLaMa-2 7B-LFT	Tulu-V2-Mix 150k	just-eval-instruct 1k	2.76	3.6	2.1	3.6	3.64	3.48	3.60
26	LLaMa-2 7B-SFT	Tulu-V2-Mix 150k	just-eval-instruct 1k	2.19	2.53	1.46	2.66	2.93	2.84	3.04
27	LLaMa-2 7B-LFT	Tulu-V2-Mix 326k	just-eval-instruct 1k	2.92	3.63	2.13	3.57	3.73	3.6	3.67
28	LLaMa-2 7B-SFT	Tulu-V2-Mix 326k	just-eval-instruct 1k	2.32	2.81	2.05	2.80	3.04	2.96	3.21
29	LLaMa-2 7B-LFT	filtered-dolly 3k	just-eval-instruct 1k	2.31	2.79	2.24	2.65	2.67	2.24	2.45
30	LLaMa-2 7B-SFT	filtered-dolly 3k	just-eval-instruct 1k	1.7	2.05	1.46	1.99	2.15	1.97	2.02
31	LLaMa-2 7B-LFT	Evol-Instruct 70k	just-eval-instruct 1k	2.78	3.56	2.08	3.55	3.66	3.49	3.76
32	LLaMa-2 7B-SFT	Evol-Instruct 70k	just-eval-instruct 1k	2.23	2.68	1.73	2.77	3.05	2.98	3.19
33	LLaMa-2 7B-LFT	LIMA-Simple 1k	just-eval-instruct 1k	2.53	2.97	1.9	2.85	2.96	2.7	2.87
34	LLaMa-2 7B-SFT	LIMA-Simple 1k	just-eval-instruct 1k	1.78	2.29	1.39	2.09	2.51	2.25	2.28
35	LLaMa-2 7B-LFT	chatgpt 9k	just-eval-instruct 1k	2.82	3.53	2.93	3.28	3.35	3.52	
36	LLaMa-2 7B-SFT	chatgpt 9k	just-eval-instruct 1k	2.58	3.13	1.82	3.01	3.15	2.72	2.93
37	LLaMa-2 7B-NFT	Alpaca 52k	just-eval-instruct 1k	1.55	2.37	1.62	2.36	2.65	2.46	2.58

Table 16. Results table 3

A Closer Look at the Limitations of Instruction Tuning

	Models	Train Set	Test Set	Coding	Info-Seek	Math	Procedure	Reasoning	Role-Play	Writing
1	LLaMa-2 _{13B} -LFT	databricks-dolly _{15k}	just-eval-instruct _{1k}	2.6	2.8	2.1	2.79	2.78	2.36	2.58
2	LLaMa-2 _{13B} -SFT	databricks-dolly _{15k}	just-eval-instruct _{1k}	1.93	2.5	1.46	2.19	2.58	1.97	2.39
3	LLaMa-2 _{13B} -LFT	LIMA _{1K}	just-eval-instruct _{1k}	2.45	2.97	2.08	2.95	2.78	2.48	2.83
4	LLaMa-2 _{13B} -SFT	LIMA _{1K}	just-eval-instruct _{1k}	1.6	2.32	1.34	2.23	2.45	1.97	2.22
5	LLaMa-2 _{13B} -LFT	Alpaca _{1K}	just-eval-instruct _{1k}	2.78	3.25	2.26	3.24	3.25	2.98	3.27
6	LLaMa-2 _{13B} -SFT	Alpaca _{1K}	just-eval-instruct _{1k}	1.86	2.44	1.67	2.27	2.55	2.11	2.49
7	LLaMa-2 _{13B} -LFT	Alpaca _{10K}	just-eval-instruct _{1k}	2.78	3.28	2.46	3.29	3.3	3.09	3.39
8	LLaMa-2 _{13B} -SFT	Alpaca _{10K}	just-eval-instruct _{1k}	1.87	2.33	1.51	2.32	2.52	2.42	2.8
9	LLaMa-2 _{13B} -LFT	Alpaca _{25K}	just-eval-instruct _{1k}	2.75	3.26	2.55	3.33	3.26	3.16	3.36
10	LLaMa-2 _{13B} -SFT	Alpaca _{25K}	just-eval-instruct _{1k}	1.65	2.17	1.45	2.12	2.36	2.1	2.57
11	LLaMa-2 _{13B} -LFT	Alpaca _{52K}	just-eval-instruct _{1k}	2.73	3.29	2.41	3.3	3.26	2.95	3.49
12	LLaMa-2 _{13B} -SFT	Alpaca _{52K}	just-eval-instruct _{1k}	1.74	2.14	1.34	2.21	2.31	2.19	2.66
13	LLaMa-2 _{13B} -LFT	Tulu-V2-Mix _{1K}	just-eval-instruct _{1k}	2.95	3.49	2.56	3.61	3.62	3.31	3.39
14	LLaMa-2 _{13B} -SFT	Tulu-V2-Mix _{1K}	just-eval-instruct _{1k}	1.88	2.71	1.63	2.58	2.81	2.55	2.56
15	LLaMa-2 _{13B} -LFT	Tulu-V2-Mix _{10K}	just-eval-instruct _{1k}	3.0	3.64	2.36	3.69	3.69	3.43	3.44
16	LLaMa-2 _{13B} -SFT	Tulu-V2-Mix _{10K}	just-eval-instruct _{1k}	1.94	2.62	1.48	2.63	2.96	2.84	3.01
17	LLaMa-2 _{13B} -LFT	Tulu-V2-Mix _{25K}	just-eval-instruct _{1k}	3.02	3.67	2.42	3.71	3.73	3.51	3.50
18	LLaMa-2 _{13B} -SFT	Tulu-V2-Mix _{25K}	just-eval-instruct _{1k}	2.01	2.82	1.72	2.84	3.08	2.95	3.14
19	LLaMa-2 _{13B} -LFT	Tulu-V2-Mix _{50K}	just-eval-instruct _{1k}	3.14	3.75	2.39	3.72	3.76	3.77	3.81
20	LLaMa-2 _{13B} -SFT	Tulu-V2-Mix _{50K}	just-eval-instruct _{1k}	2.11	2.89	1.87	2.92	3.12	3.01	3.18
21	LLaMa-2 _{13B} -LFT	Tulu-V2-Mix _{150K}	just-eval-instruct _{1k}	3.17	3.79	2.44	3.75	3.88	3.82	3.91
22	LLaMa-2 _{13B} -SFT	Tulu-V2-Mix _{150K}	just-eval-instruct _{1k}	2.29	2.95	1.98	3.02	3.21	3.27	3.38
23	LLaMa-2 _{13B} -LFT	Tulu-V2-Mix _{326k}	just-eval-instruct _{1k}	3.20	3.81	2.54	3.80	3.91	3.94	3.99
24	LLaMa-2 _{13B} -SFT	Tulu-V2-Mix _{326k}	just-eval-instruct _{1k}	2.36	3.01	2.31	3.14	3.32	3.36	3.45
25	LLaMa-2 _{13B} -LFT	LIMA-Simple _{1k}	just-eval-instruct _{1k}	2.72	3.23	2.23	3.31	3.18	2.83	3.0
26	LLaMa-2 _{13B} -SFT	LIMA-Simple _{1k}	just-eval-instruct _{1k}	1.77	2.4	1.75	2.31	2.67	2.23	2.32
27	LLaMa-2 _{70B} -LFT	databricks-dolly _{15k}	just-eval-instruct _{1k}	3.44	3.59	2.65	3.46	3.69	3.87	3.63
28	LLaMa-2 _{70B} -SFT	databricks-dolly _{15k}	just-eval-instruct _{1k}	2.42	2.53	2.33	2.45	2.61	2.45	2.78
29	LLaMa-2 _{70B} -LFT	LIMA _{1K}	just-eval-instruct _{1k}	3.32	3.54	2.59	3.40	3.58	3.72	3.58
30	LLaMa-2 _{70B} -SFT	LIMA _{1K}	just-eval-instruct _{1k}	2.36	2.49	2.31	2.41	2.57	2.43	2.71
31	LLaMa-2 _{70B} -LFT	Alpaca _{1K}	just-eval-instruct _{1k}	3.57	3.72	2.92	3.73	3.88	4.01	3.92
32	LLaMa-2 _{70B} -SFT	Alpaca _{1K}	just-eval-instruct _{1k}	3.21	2.86	2.64	2.76	2.87	2.76	3.03
33	LLaMa-2 _{70B} -LFT	Alpaca _{52K}	just-eval-instruct _{1k}	3.89	3.99	3.46	4.01	4.12	4.23	4.19
34	LLaMa-2 _{70B} -SFT	Alpaca _{52K}	just-eval-instruct _{1k}	3.42	3.14	3.05	3.10	3.33	3.11	3.45
35	LLaMa-2 _{70B} -LFT	Tulu-V2-Mix _{1k}	just-eval-instruct _{1k}	4.01	4.14	3.53	4.07	4.12	4.30	4.22
36	LLaMa-2 _{70B} -SFT	Tulu-V2-Mix _{1k}	just-eval-instruct _{1k}	3.71	3.42	3.32	3.13	3.76	3.32	3.72
37	LLaMa-2 _{70B} -LFT	Tulu-V2-Mix _{326k}	just-eval-instruct _{1k}	4.31	4.44	3.81	4.27	4.42	4.67	4.57
38	LLaMa-2 _{70B} -SFT	Tulu-V2-Mix _{326k}	just-eval-instruct _{1k}	3.92	3.72	3.62	3.35	4.11	3.67	4.01
39	Mistral-v0.1 _{7B} -LFT	databricks-dolly _{15k}	just-eval-instruct _{1k}	3.1	2.99	2.6	3.1	2.86	2.63	2.8
40	Mistral-v0.1 _{7B} -SFT	databricks-dolly _{15k}	just-eval-instruct _{1k}	1.03	1.19	1.05	1.18	1.15	1.17	1.17
41	Mistral-v0.1 _{7B} -LFT	LIMA _{1K}	just-eval-instruct _{1k}	3.14	3.01	2.5	3.28	2.85	2.59	3.0
42	Mistral-v0.1 _{7B} -SFT	LIMA _{1K}	just-eval-instruct _{1k}	1.28	1.54	1.19	1.54	1.63	1.43	1.59
43	Mistral-v0.1 _{7B} -LFT	Alpaca _{1K}	just-eval-instruct _{1k}	3.67	4.09	3.15	4.12	4.21	4.1	3.98
44	Mistral-v0.1 _{7B} -SFT	Alpaca _{1K}	just-eval-instruct _{1k}	1.26	1.55	1.53	1.49	1.55	1.47	1.65
45	Mistral-v0.1 _{7B} -LFT	Alpaca _{10K}	just-eval-instruct _{1k}	3.79	4.06	3.37	4.09	4.12	4.13	4.14
46	Mistral-v0.1 _{7B} -SFT	Alpaca _{10K}	just-eval-instruct _{1k}	1.23	1.41	1.32	1.20	1.37	1.26	1.45
47	Mistral-v0.1 _{7B} -LFT	Alpaca _{25K}	just-eval-instruct _{1k}	3.73	4.11	3.32	4.18	4.22	4.13	4.23
48	Mistral-v0.1 _{7B} -SFT	Alpaca _{25K}	just-eval-instruct _{1k}	1.12	1.18	1.21	1.19	1.17	1.13	1.23
49	Mistral-v0.1 _{7B} -LFT	Alpaca _{52K}	just-eval-instruct _{1k}	3.84	4.09	3.37	4.13	4.18	3.98	4.09
50	Mistral-v0.1 _{7B} -SFT	Alpaca _{52K}	just-eval-instruct _{1k}	1.18	1.22	1.34	1.21	1.22	1.3	1.26
51	Phi-1.5 _{1.3B} -LFT	databricks-dolly _{15k}	just-eval-instruct _{1k}	2.78	2.79	2.26	2.97	2.92	2.72	3.03
52	Phi-1.5 _{1.3B} -SFT	databricks-dolly _{15k}	just-eval-instruct _{1k}	1.9	2.31	1.79	2.36	2.58	2.57	2.55
53	Phi-1.5 _{1.3B} -LFT	LIMA _{1K}	just-eval-instruct _{1k}	3.02	2.95	2.46	3.12	2.65	2.39	2.97
54	Phi-1.5 _{1.3B} -SFT	LIMA _{1K}	just-eval-instruct _{1k}	2.58	2.64	2.32	2.51	2.42	2.12	2.78
55	Phi-1.5 _{1.3B} -LFT	Alpaca _{1K}	just-eval-instruct _{1k}	3.24	4.09	3.15	4.12	4.21	4.10	3.98
56	Phi-1.5 _{1.3B} -SFT	Alpaca _{1K}	just-eval-instruct _{1k}	1.24	1.51	1.33	1.47	1.58	1.57	1.87
57	Phi-1.5 _{1.3B} -LFT	Alpaca _{10K}	just-eval-instruct _{1k}	3.27	4.12	3.20	4.15	4.21	4.12	3.99
58	Phi-1.5 _{1.3B} -SFT	Alpaca _{10K}	just-eval-instruct _{1k}	1.45	1.51	1.47	1.65	1.75	1.82	2.01
59	Phi-1.5 _{1.3B} -LFT	Alpaca _{25K}	just-eval-instruct _{1k}	3.29	4.13	3.22	4.17	4.23	4.11	4.00
60	Phi-1.5 _{1.3B} -SFT	Alpaca _{25K}	just-eval-instruct _{1k}	1.71	1.82	1.72	1.83	1.81	2.01	2.14
61	Phi-1.5 _{1.3B} -LFT	Alpaca _{52K}	just-eval-instruct _{1k}	3.28	4.10	3.21	4.19	4.25	4.12	4.03
62	Phi-1.5 _{1.3B} -SFT	Alpaca _{52K}	just-eval-instruct _{1k}	1.59	1.92	1.72	1.97	2.13	2.23	3.02

Table 17. Results table 3